

# 陈小宇

186-0292-0361 | rain1104@foxmail.com | 杭州 | [github.com/Rain1601](https://github.com/Rain1601)

## Agent 开发工程师 | 通用 Agent 系统 | 投研 Agent

后端 / Agent 工程师，关注可运行、可观察、可评估、可迭代的 Agent 系统。

在阿里云参与并主导实时语音 Agent 核心链路建设，支撑高并发生产环境，将端到端对话延迟从 3s+ 优化至 1.5-1.8s。

独立设计并实现投研 Agent Uteki，围绕证据约束、时间一致性、结构化推理、execution trace 和多模型评估，探索 Agent 在复杂投研决策中的工程化落地。

### 教育经历

西安交通大学 · 软件工程 硕士 2020.09 – 2023.07（电信学部） · 学士 2016.09 – 2020.06（软件学院）

### 工作经历

阿里云智能 · 后端 / Agent 开发工程师 2023.07 – 至今，2024.10 起转 Agent 方向

### Agent 项目

营销语音 Agent · 阿里云智能营销数字人

项目链接：[aliyun.com/product/thirdsw/aiemployee](https://aliyun.com/product/thirdsw/aiemployee)

面向企业自动化外呼、销售转化和 7x24 客户交互场景，构建高并发下的低延迟实时语音 Agent。作为后端核心开发，主导智能外呼系统链路构建与迭代，重点解决实时语音对话中的低延迟、可打断、多轮一致性和策略平台化问题。

#### Agent 推理链路与时延优化

- 设计端到端流式链路：ASR → LLM 决策（tool calling + RAG）→ TTS，降低等待时间和首包延迟
- 结合 vLLM 推理加速与 LLM Cache，端到端对话延迟从 3s+ → 1.5-1.8s
- 通过双 VAD、双路 ASR 和降噪模型（Omni3），系统性优化打断、抢话、专有词识别和环境噪声场景

#### Agent 平台化与策略迭代

- 将单一外呼流程升级为可配置 Agent 平台，按业务目标组合系统 Prompt、知识库、工具集和执行策略
- 建设在线调试、版本管理和 A/B 灰度能力，对话策略迭代周期从天级 → 小时级
- 基于函数调用和 RAG 构建对话策略体系，支持上传语料后自动生成 QA 对并接入业务流程

业务规模：日均 10 万+ 外呼，峰值 200 QPM（约每小时 1 万通），稳定支撑 200+ 并发

投研 Agent · Uteki（雨滴）

项目链接：[v1](#) | [v2](#) | [v3](#)

面向 标普 500 / Nasdaq 100 中“清晰可见”的高质量公司，构建可审计、可回放、可评估的投研 Agent。

#### 核心设计原则

- 证据先于结论：Agent 不直接生成投资判断，而是先构建 SourceCatalog，将财报、市场数据、新闻和搜索结果统一为带来源、时间、置信度的 DataPoint
- 分阶段推理：将公司研究拆解为 7-Gate 决策链——业务质量 → Fisher 增长 → Buffett 护城河 → Munger 管理层 → 反向测试 → 估值 → 综合裁决
- 受约束的自主性：每个 Gate 可调用工具，但输出必须包含结构化结论、置信度和 [src:N] 引用；parser 校验引用合法性，避免无来源推理
- 时间一致性：引入 as\_of 时间窗约束数据和来源时间，支持历史回测，严格避免 lookahead bias
- 可观察与可评估：持久化 execution trace、gate output、tool calls 和 citation，支持 replay 审计；通过 ConsistencyRunner 和 Arena 评估多次运行稳定性

#### 工程实现

- FastAPI + React 构建完整 Agent 工作台，支持 SSE 流式执行、运行记录、断线恢复、结果回放
- Pydantic 约束每个 Gate 的结构化输出，降低自由文本不可控问题
- Reflection Checkpoint 检测跨 Gate 矛盾，并将上游结论作为下游推理上下文
- Arena 3-phase（Decide → Vote → Tally），多 LLM 独立判断 + 匿名互评，提高结论稳定性

投研 Agent · Shinkai（深海 · 进行中）

项目链接：[github.com/Rain1601/shinkai](https://github.com/Rain1601/shinkai)

面向“市场尚未充分覆盖”的潜在优质公司，探索从 公司发现 → 初筛 → 假设生成 → 深度研究 的主动式投研 Agent。

- 与 Uteki 的差异：Uteki 偏深度审计已知公司，Shinkai 偏主动发现未知机会——共同构成 Research → Discovery 完整闭环
- 候选池发现流程：从财务质量、增长异常、估值错配、行业变化和市场忽视信号中生成研究对象
- Hypothesis-first 研究链路：先生成投资假设，再反向搜索证据验证或证伪，避免只做信息汇总
- 目标形成 发现 → 假设 → 证据 → 反证 → 深度研究 端到端投研 Agent 流程

### 后端项目

云栖大会核心系统 · 阿里云智能

- 主导核心运营后台、票证、展商、云上峰会等多模块开发与稳定性建设
- 2024 / 2025 年云栖大会应用开发与技术 PM，协调多团队推进需求交付与变更管理
- 支撑累计 8.7 万+ 用户报名与参会，峰值 200 QPM，系统可用性 99.9%
- 主导内容审核系统智能化升级，处理 800 万文件，自动化覆盖 95%，审核人效 +70%

### 长期方向

我致力于长期探索应用 Agent 解决现实世界的复杂问题，将优秀决策认知与经验转化为可持续演化的系统。

在未来，长期聚焦于 AI 与投资研究的结合，将优秀投资的思考框架结构化、工程化，并通过 Agent 持续验证、优化与迭代决策质量。