

陈小宇

186-0292-0361 | rain1104@foxmail.com | 杭州 | github.com/Rain1601

Agent 开发工程师 | 通用 Agent 系统 | 投研 Agent

后端 / Agent 工程师，关注可运行、可观察、可评估、可迭代的 Agent 系统在真实业务与复杂决策中的工程化落地。

在阿里云主导实时语音 Agent 核心链路建设，将端到端对话延迟从 3s+ 压缩至 1.5-1.8s，稳定支撑日均 10 万+ 调用的高并发生产环境。

工作之外长期独立推进投研 Agent —— Uteki 研究“清晰可见”的高质量公司、Shinkai 探索“尚未被覆盖”的潜在机会；围绕证据约束、时间一致性、结构化推理、execution trace 与多模型评估，共同构成 Research → Discovery 完整闭环。

教育经历

西安交通大学 · 软件工程 硕士 2020.09 – 2023.07 (电信学部) · 学士 2016.09 – 2020.06 (软件学院)

工作经历

阿里云智能 · 后端 / Agent 开发工程师 2023.07 – 至今，2024.10 起转 Agent 方向

Agent 项目

营销语音 Agent · 阿里云智能营销数字人

项目链接：aliyun.com/product/thirdsw/aiemployee

面向企业自动化外呼、销售转化和 7x24 客户交互场景，构建高并发下的低延迟实时语音 Agent。作为后端核心开发，主导智能外呼系统链路构建与迭代，重点解决实时语音对话中的低延迟、可打断、多轮一致性和策略平台化问题。

Agent 推理链路与时延优化

- 设计端到端流式链路：ASR → LLM 决策 (tool calling + RAG) → TTS，降低等待时间和首包延迟
- 结合 vLLM 推理加速与 LLM Cache，端到端对话延迟从 3s+ → 1.5-1.8s
- 通过双 VAD、双路 ASR 和降噪模型 (Omni3)，系统性优化打断、抢话、专有词识别和环境噪声场景

Agent 平台化与策略迭代

- 将单一外呼流程升级为可配置 Agent 平台，按业务目标组合系统 Prompt、知识库、工具集和执行策略
- 建设在线调试、版本管理和 A/B 灰度能力，对话策略迭代周期从天级 → 小时级
- 基于函数调用和 RAG 构建对话策略体系，支持上传语料后自动生成 QA 对并接入业务流程

业务规模：日均 10 万+ 外呼，峰值 200 QPM (约每小时 1 万通)，稳定支撑 200+ 并发

投研 Agent · Uteki (雨滴)

项目链接：[v1](#) | [v2](#) | [v3](#)

面向 标普 500 / Nasdaq 100 高质量公司构建可审计、可回放、可评估的投研决策基础设施 —— 输出结构化 dossier 与决策证据链，为策略实证提供可信 ground truth。

核心设计原则

- 证据先于结论：Agent 不直接生成投资判断，而是先构建 SourceCatalog，将财报、市场数据、新闻和搜索结果统一为带来源、时间、置信度的 DataPoint
- 分阶段推理：将公司研究拆解为 7-Gate 决策链 —— 业务质量 → Fisher 增长 → Buffett 护城河 → Munger 管理层 → 反向测试 → 估值 → 综合裁决
- 受约束的自主性：每个 Gate 可调用工具，但输出必须包含结构化结论、置信度和 [src:N] 引用；parser 校验引用合法性，避免无来源推理
- 时间一致性：引入 as_of 时间窗约束数据和来源时间，支持历史回测，严格避免 lookahead bias
- 可观察与可评估：持久化 execution trace、gate output、tool calls 和 citation，支持 replay 审计；通过 ConsistencyRunner 和 Arena 评估多次运行稳定性

工程实现

- FastAPI + React + Pydantic 构建完整工作台 —— SSE 流式执行 / 运行记录 / 断线恢复 / 结果回放；Reflection Checkpoint 跨 Gate 矛盾检测；Arena 3-phase (Decide → Vote → Tally) 多 LLM 匿名互评

投研 Agent · Shinkai (深海 · 进行中)

项目链接：github.com/Rain1601/shinkai

面向“市场尚未充分覆盖”的潜在优质公司，探索 公司发现 → 初筛 → 假设生成 → 证据验证 → 深度研究 的主动式投研 Agent；与 Uteki 互补，构成 Research → Discovery 完整闭环。

- 主题驱动的供应链追溯 (Mode B)：给定产业主题 (已实现 AI 算力供应链首跑)，系统从龙头逐层追溯依赖 (NVIDIA → 晶圆 → 光学 → 散热)，每层产出 candidate 与排序
- Hypothesis-first + Research Graph：先假设后反向搜索证据验证 / 证伪，持久化为下游可消费的图结构 (Entity / Claim / Evidence / Question / Thesis 五类节点)
- 多角色批判 + 有界自迭代：Planner / Reviewer / Optimizer + L2 critic 反证搜索；hypothesis state machine 驱动迭代，tool-call 预算硬约束防失控

后端项目

云栖大会核心系统 · 阿里云智能

- 内容审核 LLM 化 (Agent 在传统业务侧的早期落地)：800 万文件规模下落地 LLM + 规则引擎协同管线，自动化覆盖 95%、审核人效 +70%
- 主导云栖大会核心系统 (运营后台 / 票证 / 展商 / 云上峰会)，8.7 万+ 用户报名、峰值 200 QPM、可用性 99.9%
- 2024 / 2025 年云栖大会应用开发与技术 PM，协调多团队推进需求与变更管理

长期方向

我相信优秀的投资决策可以被结构化、工程化、可持续迭代 —— 决策可信度是工程问题。下一阶段在 Uteki + Shinkai 这套基础设施上完成多年回测与实证，把方法论沉淀为可在垂直行业 (AI 算力 / 半导体 / 生物医药) 反复使用的投研 Agent 框架。